

Kelompok : D

Nama : - Nasywa Putri Maitsa (K1D024043)
- Nadia Marsha (K1D024046)
- Raditya Akbar Firdaus (K1D024063)
- Kezya Aurell Manuella Sihotang (K1D024071)

Nama Dataset : Medical Cost Personal Dataset (Insurance Dataset)

Sumber Data : Kaggle

Link Dataset :

<https://www.kaggle.com/code/mragpavank/medical-cost-personal-datasets/input>

1. Jumlah Observasi dan Variabel

- Jumlah observasi (baris): 1.338
- Jumlah variabel (kolom): 7

2. Karakteristik Data

Dataset ini berisi informasi mengenai karakteristik individu dan biaya asuransi kesehatan yang harus dibayarkan. Data bersifat cross-sectional karena dikumpulkan dari banyak individu pada satu periode tertentu.

Variabel	Tipe Data	Keterangan
age	Numerik (integer)	Usia pemegang asuransi
sex	Kategorik	Jenis kelamin (male/female)
bmi	Numerik (float)	Body Mass Index (BMI)
children	Numerik (integer)	Jumlah anak/tanggungan
smoker	Kategorik	Status perokok (yes/no)
region	Kategorik	Wilayah tempat tinggal
charges	Numerik (float)	Biaya asuransi kesehatan yang dibebankan

3. Variabel Target

Variabel Target: charges

Alasan:

- Nilainya dipengaruhi oleh karakteristik individu seperti usia, BMI, jumlah anak, status merokok, jenis kelamin, dan wilayah tempat tinggal.
- Variabel ini berbentuk numerik kontinu sehingga sesuai untuk pemodelan regresi.
- Dalam konteks bisnis asuransi, prediksi biaya kesehatan sangat penting untuk menentukan premi dan mengelola risiko.

4. Variabel Prediktor (Independent Variables)

- age
- sex
- bmi
- children
- smoker
- region

5. Tujuan Analisis

Menganalisis serta memprediksi besarnya biaya asuransi kesehatan (charges) berdasarkan karakteristik pemegang asuransi, sehingga dapat diketahui faktor-faktor yang paling berpengaruh terhadap biaya tersebut.