

LAPORAN PROJECT MACHINE LEARNING
ANALISIS REGRESI PREMI ASURANSI KESEHATAN DENGAN PENDEKATAN
MACHINE LEARNING

Dosen Pengampu:

Luthfia Maharani, S.Stat., M.Stat.



Disusun Oleh :

- | | | |
|----|---------------------------|-----------|
| 1. | Nasywa Putri Maitsa | K1D024043 |
| 2. | Nadia Marsha | K1D024046 |
| 3. | Raditya Akbar Firdaus | K1D023063 |
| 4. | Kezuya Aurell Manuela .S. | K1D024071 |

PROGRAM STUDI STATISTIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS JENDERAL SOEDIRMAN
TAHUN AJARAN 2025/2026

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi informasi dan ketersediaan data dalam jumlah besar telah mendorong pemanfaatan machine learning di berbagai bidang, salah satunya pada sektor kesehatan dan asuransi. Machine learning memungkinkan komputer untuk mempelajari pola dari data historis sehingga dapat digunakan untuk melakukan prediksi maupun pengambilan keputusan secara lebih efektif dan efisien.

Dalam industri asuransi kesehatan, prediksi biaya kesehatan menjadi salah satu aspek penting karena berkaitan dengan penentuan premi, pengelolaan risiko, serta perencanaan keuangan perusahaan. Besarnya biaya kesehatan yang harus ditanggung oleh peserta asuransi dipengaruhi oleh berbagai faktor, seperti usia, jenis kelamin, indeks massa tubuh (Body Mass Index/BMI), jumlah tanggungan, kebiasaan merokok, serta wilayah tempat tinggal. Oleh karena itu, diperlukan suatu metode yang mampu mengidentifikasi hubungan antara faktor-faktor tersebut dengan biaya kesehatan yang dikeluarkan.

Machine learning dapat dimanfaatkan untuk membangun model prediksi biaya asuransi kesehatan berdasarkan karakteristik peserta asuransi. Dengan memanfaatkan data historis, model yang dihasilkan dapat membantu memperkirakan biaya kesehatan secara lebih akurat serta mengidentifikasi faktor-faktor yang memiliki pengaruh terbesar terhadap biaya tersebut. Informasi ini dapat digunakan sebagai bahan pertimbangan dalam pengambilan keputusan yang berkaitan dengan pengelolaan layanan asuransi kesehatan.

Pada penelitian ini digunakan dataset Insurance yang berisi data karakteristik peserta asuransi kesehatan dan biaya kesehatan yang dikeluarkan. Variabel yang tersedia dalam dataset meliputi usia (age), jenis kelamin (sex), indeks massa tubuh (bmi), jumlah anak atau tanggungan (children), status merokok (smoker), wilayah tempat tinggal (region), serta biaya asuransi kesehatan (charges). Variabel charges digunakan sebagai variabel target yang akan diprediksi sehingga penelitian ini termasuk ke dalam permasalahan regresi.

Penelitian ini bertujuan untuk menerapkan beberapa algoritma machine learning dalam memprediksi biaya asuransi kesehatan, membandingkan performa masing-masing model, serta mengidentifikasi faktor-faktor yang paling berpengaruh terhadap biaya asuransi kesehatan. Hasil penelitian diharapkan dapat memberikan pemahaman mengenai penerapan machine learning pada permasalahan prediksi biaya asuransi kesehatan serta menghasilkan model dengan performa prediksi yang baik.

1.2 Rumusan Masalah

1. Bagaimana karakteristik dan pola data pada dataset Insurance berdasarkan hasil Exploratory Data Analysis (EDA)?
2. Bagaimana proses preprocessing dan feature engineering yang tepat untuk meningkatkan kualitas data sebelum pemodelan?
3. Bagaimana performa beberapa algoritma machine learning dalam memprediksi biaya asuransi kesehatan (charges)?
4. Model machine learning manakah yang memberikan hasil prediksi terbaik berdasarkan matrik evaluasi yang digunakan?
5. Faktor-faktor apa saja yang paling berpengaruh terhadap biaya asuransi kesehatan berdasarkan hasil interpretasi model?

1.3 Tujuan Penelitian

1. Melakukan eksplorasi data untuk memahami karakteristik dan pola pada dataset Insurance.
2. Menerapkan tahapan preprocessing dan feature engineering guna mempersiapkan data untuk proses pemodelan.
3. Membangun dan membandingkan beberapa algoritma machine learning untuk memprediksi biaya asuransi kesehatan.
4. Mengevaluasi dan menentukan model terbaik berdasarkan hasil pengukuran performa model.
5. Mengidentifikasi faktor-faktor yang paling berpengaruh terhadap biaya asuransi kesehatan melalui analisis feature importance atau interpretasi model.

1.4 Manfaat

1. Manfaat Teoritis

Penelitian ini diharapkan dapat memperkaya pengetahuan dan wawasan mengenai penerapan metode machine learning dalam menyelesaikan permasalahan prediksi pada bidang kesehatan dan asuransi. Selain itu, penelitian ini juga dapat menjadi referensi bagi pengembangan penelitian selanjutnya yang berkaitan dengan pemodelan regresi, evaluasi performa algoritma machine learning, serta analisis faktor-faktor yang mempengaruhi biaya asuransi kesehatan.

2. Manfaat Praktis

a. Perusahaan Asuransi

Hasil penelitian ini dapat digunakan sebagai bahan pertimbangan dalam memperkirakan biaya kesehatan peserta asuransi berdasarkan karakteristik yang dimiliki. Model prediksi yang dihasilkan juga dapat membantu perusahaan dalam melakukan pengelolaan risiko, penyusunan strategi bisnis, serta pengambilan keputusan yang lebih efektif dan berbasis data.

b. Masyarakat atau Peserta Asuransi

Penelitian ini dapat memberikan pemahaman mengenai faktor-faktor yang mempengaruhi besarnya biaya asuransi kesehatan, seperti usia, indeks massa tubuh (BMI), jumlah tanggungan, dan kebiasaan merokok. Dengan mengetahui faktor-faktor tersebut, masyarakat diharapkan dapat lebih memahami pentingnya menjaga pola hidup sehat untuk mengurangi risiko peningkatan biaya kesehatan di masa mendatang.

c. Peneliti

Penelitian ini dapat menjadi sarana untuk menerapkan dan mengembangkan pemahaman mengenai tahapan machine learning secara menyeluruh, mulai dari eksplorasi data, preprocessing, feature engineering, pemodelan, hyperparameter tuning, hingga evaluasi dan interpretasi model. Selain itu, penelitian ini juga dapat meningkatkan kemampuan analisis data dan pemecahan masalah berbasis data.

d. Akademisi

Penelitian ini dapat menjadi referensi dan sumber informasi bagi mahasiswa maupun peneliti lain yang ingin mempelajari penerapan machine learning pada

permasalahan prediksi biaya asuransi kesehatan. Hasil penelitian ini juga dapat digunakan sebagai bahan perbandingan dalam penelitian serupa dengan dataset maupun metode yang berbeda.

BAB II

TINJAUAN DATASET DAN TINJAUAN PUSTAKA

2.1 Deskripsi Dataset

Dataset yang digunakan dalam penelitian ini adalah Medical Cost Personal Dataset (Insurance Dataset) yang berisi informasi mengenai karakteristik peserta asuransi kesehatan dan biaya kesehatan yang ditanggung oleh perusahaan asuransi. Dataset ini banyak digunakan dalam penelitian machine learning karena memiliki kombinasi variabel numerik dan kategorik yang dapat digunakan untuk membangun model prediksi biaya asuransi kesehatan.

Dataset terdiri dari 1.338 observasi dan 7 variabel, yang terdiri atas enam variabel prediktor (fitur) dan satu variabel target. Variabel target pada penelitian ini adalah charges, yaitu biaya asuransi kesehatan yang dikeluarkan oleh peserta. Karena variabel target berbentuk numerik kontinu, maka penelitian ini termasuk ke dalam permasalahan regresi (regression problem).

Data yang digunakan memuat informasi mengenai usia peserta, jenis kelamin, indeks massa tubuh (BMI), jumlah tanggungan anak, status merokok, wilayah tempat tinggal, serta biaya asuransi kesehatan yang dibayarkan. Dataset ini dipilih karena memiliki jumlah data yang memadai, karakteristik yang beragam, serta relevan untuk diterapkan pada berbagai algoritma machine learning regresi.

2.2 Data Dictionary

Berikut deskripsi variabel yang digunakan dalam penelitian:

No	Variabel	Tipe Data	Keterangan
1	Age	INT	Usia peserta asuransi (tahun)
2	Sex	Object	Jenis kelamin peserta (male/female)
3	BMI	INT	Body Mass Index (BMI) atau indeks massa tubuh peserta
4	Children	INT	Jumlah anak atau tanggungan yang dimiliki peserta

5	Smoker	Object	Status merokok peserta (yes/no)
6	Region	Object	Wilayah tempat tinggal peserta (northeast, northwest, southeast, southwest)
7	Charges	INT	Biaya asuransi kesehatan yang dibayarkan peserta (target)

Berdasarkan data dictionary tersebut, variabel charges digunakan sebagai variabel target (dependent variable), sedangkan variabel age, sex, bmi, children, smoker, dan region digunakan sebagai variabel fitur (independent variables).

2.3 Dasar Teori

2.3.1 Machine Learning

Machine Learning merupakan salah satu cabang dari Artificial Intelligence (AI) yang berfokus pada pengembangan sistem yang mampu mempelajari pola dari data dan menghasilkan prediksi atau keputusan tanpa harus diprogram secara eksplisit. Melalui proses pembelajaran dari data historis, model machine learning dapat mengenali hubungan antar variabel dan menggunakannya untuk memprediksi data baru.

Secara umum, machine learning dibagi menjadi tiga kategori utama, yaitu supervised learning, unsupervised learning, dan reinforcement learning. Pada penelitian ini digunakan pendekatan supervised learning karena data yang digunakan memiliki variabel target yang sudah diketahui, yaitu biaya asuransi kesehatan (charges).

Penerapan machine learning telah banyak digunakan pada berbagai bidang seperti kesehatan, keuangan, pendidikan, pemasaran, dan industri. Dalam penelitian ini, machine learning dimanfaatkan untuk membangun model prediksi biaya asuransi kesehatan berdasarkan karakteristik peserta asuransi.

2.3.2 Regresi

Regresi merupakan salah satu metode *supervised learning* yang digunakan untuk memprediksi nilai numerik kontinu berdasarkan hubungan antara variabel independen (fitur) dan

variabel dependen (target). Tujuan utama regresi adalah membangun model yang dapat menjelaskan hubungan antar variabel serta menghasilkan prediksi terhadap data baru.

Metode regresi banyak digunakan dalam berbagai bidang, seperti prediksi harga rumah, penjualan, permintaan pasar, hingga biaya kesehatan. Selain untuk melakukan prediksi, regresi juga dapat digunakan untuk mengetahui pengaruh masing-masing variabel prediktor terhadap variabel target.

Pada penelitian ini, regresi digunakan untuk memprediksi biaya asuransi kesehatan (*charges*) berdasarkan karakteristik peserta asuransi, yaitu usia (*age*), jenis kelamin (*sex*), indeks massa tubuh (*bmi*), jumlah tanggungan (*children*), status merokok (*smoker*), dan wilayah tempat tinggal (*region*). Karena variabel *charges* berupa data numerik kontinu, maka penelitian ini termasuk ke dalam permasalahan regresi.

Model regresi yang baik diharapkan mampu menghasilkan nilai prediksi yang mendekati nilai aktual sehingga dapat digunakan sebagai dasar dalam pengambilan keputusan yang lebih akurat.

2.3.3 Teorema Limit Pusat (Central Limit Theorem)

Teorema Limit Pusat (Central Limit Theorem/CLT) menyatakan bahwa distribusi rata-rata sampel yang diambil secara acak dari suatu populasi akan mendekati distribusi normal apabila ukuran sampel cukup besar, terlepas dari bentuk distribusi populasi asalnya. Dalam praktik statistik, ukuran sampel sebesar 30 atau lebih umumnya dianggap telah memenuhi pendekatan distribusi normal.

Pada penelitian ini, jumlah observasi yang digunakan sebanyak 1.338 data sehingga ukuran sampel dapat dikatakan cukup besar. Kondisi tersebut memungkinkan statistik deskriptif yang diperoleh dari data memberikan gambaran yang representatif terhadap karakteristik dataset yang digunakan dalam penelitian.

2.3.4 Exploratory Data Analysis (EDA)

Exploratory Data Analysis (EDA) merupakan tahap awal dalam proses analisis data yang bertujuan untuk memahami karakteristik dataset sebelum dilakukan pemodelan. Tahapan ini sangat penting karena dapat membantu peneliti memperoleh gambaran umum mengenai struktur data yang digunakan.

EDA dilakukan melalui analisis statistik deskriptif dan visualisasi data. Statistik deskriptif meliputi nilai rata-rata, median, standar deviasi, nilai minimum, dan nilai maksimum. Sementara itu, visualisasi data dapat dilakukan menggunakan histogram, boxplot, scatter plot, dan heatmap korelasi.

Melalui EDA, peneliti dapat mengidentifikasi distribusi data, hubungan antar variabel, keberadaan outlier, data duplikat, serta pola-pola yang berpotensi mempengaruhi performa model machine learning.

2.3.5 Data Preprocessing

Data preprocessing merupakan proses persiapan data sebelum digunakan dalam pemodelan machine learning. Kualitas data yang baik akan berpengaruh langsung terhadap performa model yang dihasilkan.

Beberapa tahapan preprocessing yang umum dilakukan meliputi penanganan missing value, penghapusan data duplikat, encoding variabel kategorik, penanganan outlier, serta normalisasi atau standarisasi data numerik.

Selain itu, dataset biasanya dibagi menjadi data pelatihan (training data) dan data pengujian (testing data). Pembagian ini bertujuan untuk mengukur kemampuan model dalam melakukan prediksi terhadap data yang belum pernah dilihat sebelumnya.

2.3.6 Feature Engineering

Feature engineering merupakan proses pembuatan, transformasi, atau pemilihan fitur yang digunakan dalam model machine learning. Tujuan utama feature engineering adalah meningkatkan kualitas informasi yang tersedia sehingga model dapat mempelajari pola data dengan lebih baik.

Proses ini dapat dilakukan melalui pembuatan fitur baru, transformasi data, penggabungan variabel, maupun seleksi fitur yang dianggap paling relevan terhadap variabel target. Feature engineering yang baik dapat meningkatkan akurasi dan kemampuan generalisasi model.

2.3.7 Algoritma Machine Learning

a. Linear Regression

Linear Regression merupakan salah satu algoritma regresi yang digunakan untuk memodelkan hubungan linear antara variabel independen dan variabel dependen. Algoritma ini bekerja dengan mencari garis terbaik yang dapat menggambarkan hubungan antara variabel prediktor dengan variabel target sehingga kesalahan prediksi yang dihasilkan menjadi seminimal mungkin.

Linear Regression banyak digunakan karena memiliki konsep yang sederhana, mudah diinterpretasikan, dan mampu memberikan gambaran mengenai pengaruh masing-masing variabel terhadap target. Selain itu, model ini sering digunakan sebagai model dasar (*baseline model*) untuk membandingkan performa algoritma lain yang lebih kompleks.

Persamaan umum Linear Regression adalah:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n + \varepsilon$$

dengan:

- Y = variabel target
- β_0 = intercept
- $\beta_1, \beta_2, \dots, \beta_n$ = koefisien regresi
- X = variabel prediktor
- ε = error

Pada penelitian ini, Linear Regression digunakan sebagai model baseline untuk memprediksi biaya asuransi kesehatan (*charges*) berdasarkan karakteristik peserta asuransi. Model ini dipilih karena mampu menggambarkan hubungan linear antara variabel prediktor, seperti usia (*age*), indeks massa tubuh (*bmi*), jumlah tanggungan (*children*), status merokok (*smoker*), wilayah

tempat tinggal (*region*), dan jenis kelamin (*sex*), terhadap variabel target. Hasil yang diperoleh dari Linear Regression digunakan sebagai dasar pembandingan untuk mengevaluasi apakah algoritma yang lebih kompleks, seperti Decision Tree, Random Forest, dan XGBoost, mampu memberikan peningkatan performa prediksi yang lebih baik. Selain itu, koefisien regresi yang dihasilkan juga dapat memberikan gambaran mengenai arah dan besarnya pengaruh masing-masing variabel terhadap biaya asuransi kesehatan.

b. KNN

K-Nearest Neighbor (KNN) Regression merupakan algoritma machine learning yang digunakan untuk memprediksi nilai numerik berdasarkan kedekatan atau kemiripan data. Algoritma ini bekerja dengan mencari sejumlah data yang paling dekat dengan data yang akan diprediksi, kemudian memanfaatkan informasi dari data-data tersebut untuk menghasilkan nilai prediksi.

Pada KNN Regression, prediksi dilakukan dengan menghitung jarak antara data baru dan seluruh data pelatihan. Selanjutnya, dipilih sejumlah tetangga terdekat sesuai nilai parameter k yang telah ditentukan. Nilai prediksi diperoleh dari rata-rata nilai target milik k tetangga terdekat tersebut. Oleh karena itu, pemilihan nilai k yang tepat sangat berpengaruh terhadap performa model.

KNN Regression memiliki kelebihan berupa kemudahan implementasi, tidak memerlukan asumsi tertentu terhadap distribusi data, serta mampu menangkap hubungan nonlinier antarvariabel. Namun, algoritma ini sensitif terhadap perbedaan skala data sehingga umumnya memerlukan proses normalisasi atau standarisasi sebelum pemodelan. Pada penelitian ini, KNN Regression digunakan untuk memprediksi biaya asuransi kesehatan (*charges*) dan hasilnya dibandingkan dengan algoritma lainnya untuk menentukan model terbaik.

c. Decision Tree

Decision Tree Regression merupakan algoritma machine learning yang digunakan untuk memprediksi nilai numerik dengan membentuk struktur pohon keputusan (*decision tree*). Algoritma ini bekerja dengan membagi data ke dalam beberapa kelompok berdasarkan nilai variabel tertentu sehingga data yang berada dalam kelompok yang sama memiliki karakteristik

yang relatif seragam. Pembagian data dilakukan secara bertahap mulai dari simpul utama (*root node*) hingga terbentuk simpul akhir (*leaf node*) yang berisi nilai prediksi.

Dalam proses pembentukan pohon, algoritma akan memilih variabel dan titik pemisah (*split point*) yang mampu menghasilkan penurunan kesalahan prediksi terbesar. Setiap percabangan yang terbentuk merepresentasikan suatu aturan keputusan berdasarkan nilai variabel tertentu. Proses ini dilakukan secara berulang hingga mencapai kondisi penghentian yang telah ditentukan, seperti kedalaman pohon maksimum atau jumlah minimum data pada setiap simpul.

Pada permasalahan regresi, nilai prediksi pada setiap *leaf node* umumnya diperoleh dari rata-rata nilai target data yang berada pada node tersebut. Ketika data baru dimasukkan ke dalam model, data akan mengikuti aturan percabangan dari *root node* hingga mencapai *leaf node*, kemudian nilai pada *leaf node* tersebut digunakan sebagai hasil prediksi.

Salah satu keunggulan utama Decision Tree Regression adalah kemampuannya dalam menangkap hubungan yang kompleks dan nonlinier antarvariabel tanpa memerlukan asumsi tertentu mengenai distribusi data. Selain itu, model ini mudah dipahami dan diinterpretasikan karena proses pengambilan keputusan dapat divisualisasikan dalam bentuk pohon yang menunjukkan bagaimana suatu prediksi dihasilkan.

Meskipun demikian, Decision Tree Regression memiliki kelemahan berupa kecenderungan mengalami *overfitting*, terutama jika pohon yang dibentuk terlalu dalam dan kompleks. Kondisi ini dapat menyebabkan model memiliki performa yang sangat baik pada data pelatihan, tetapi kurang mampu melakukan generalisasi terhadap data baru. Oleh karena itu, diperlukan pengaturan parameter seperti *max_depth*, *min_samples_split*, dan *min_samples_leaf* untuk mengontrol kompleksitas model dan meningkatkan kemampuan prediksinya.

d. Random Forest Regression

Random Forest Regression merupakan algoritma *ensemble learning* yang dibangun dari kumpulan beberapa Decision Tree. Algoritma ini bekerja dengan membuat banyak pohon keputusan menggunakan sampel data yang dipilih secara acak (*bootstrap sampling*). Selain menggunakan sampel data yang berbeda, setiap pohon juga dibangun dengan mempertimbangkan sebagian fitur yang dipilih secara acak sehingga menghasilkan variasi antar pohon yang terbentuk.

Pada permasalahan regresi, setiap Decision Tree akan menghasilkan nilai prediksi berdasarkan pola yang dipelajarinya dari data pelatihan. Selanjutnya, hasil prediksi dari seluruh pohon akan digabungkan dan dirata-ratakan untuk menghasilkan prediksi akhir. Pendekatan ini memungkinkan model memanfaatkan keunggulan banyak pohon keputusan sekaligus mengurangi pengaruh kesalahan yang mungkin terjadi pada masing-masing pohon.

Dengan mengkombinasikan sejumlah Decision Tree, Random Forest mampu menghasilkan model yang lebih stabil dan memiliki kemampuan generalisasi yang lebih baik dibandingkan Decision Tree tunggal. Algoritma ini juga lebih tahan terhadap *overfitting* karena prediksi akhir tidak bergantung pada satu pohon tertentu, melainkan merupakan hasil agregasi dari banyak pohon keputusan.

Selain memiliki tingkat akurasi yang baik, Random Forest mampu menangani data dengan hubungan yang kompleks, baik yang bersifat linear maupun nonlinier. Algoritma ini juga relatif robust terhadap keberadaan outlier dan variasi data sehingga sering digunakan dalam berbagai permasalahan prediksi. Keunggulan lainnya adalah kemampuannya dalam mengukur tingkat kepentingan variabel (*feature importance*), sehingga dapat membantu mengidentifikasi faktor-faktor yang paling berpengaruh terhadap variabel target.

Pada penelitian ini, Random Forest Regression digunakan untuk memprediksi biaya asuransi kesehatan (*charges*) berdasarkan karakteristik peserta asuransi. Hasil yang diperoleh kemudian dibandingkan dengan algoritma lainnya untuk menentukan model yang memiliki performa prediksi terbaik.

e. XGBoost Regression

XGBoost (*Extreme Gradient Boosting*) merupakan salah satu algoritma machine learning berbasis *boosting* yang dikembangkan untuk meningkatkan akurasi prediksi melalui proses pembelajaran secara bertahap. Algoritma ini bekerja dengan membangun sejumlah model secara berurutan, di mana setiap model baru dibuat untuk memperbaiki kesalahan prediksi yang dihasilkan oleh model sebelumnya. Dengan cara tersebut, model secara bertahap mampu mempelajari pola data yang semakin kompleks dan menghasilkan prediksi yang lebih akurat.

Pada XGBoost, setiap pohon keputusan (*decision tree*) yang dibangun berfokus pada data yang masih memiliki tingkat kesalahan prediksi tinggi. Kesalahan tersebut digunakan sebagai dasar untuk membentuk pohon berikutnya sehingga model dapat terus meningkatkan performanya dari satu iterasi ke iterasi berikutnya. Prediksi akhir diperoleh dari penggabungan kontribusi seluruh pohon yang telah dibangun selama proses pelatihan.

Salah satu keunggulan utama XGBoost dibandingkan metode boosting lainnya adalah kemampuannya dalam melakukan optimasi secara efisien. Algoritma ini dilengkapi dengan teknik regularisasi yang berfungsi untuk mengendalikan kompleksitas model sehingga dapat mengurangi risiko *overfitting*. Selain itu, XGBoost juga mendukung penanganan data dalam jumlah besar, proses komputasi yang cepat, serta kemampuan untuk menangani hubungan non linier antar variabel dengan baik.

XGBoost memiliki beberapa hyperparameter penting yang dapat mempengaruhi performa model, seperti *n_estimators* yang menentukan jumlah pohon yang dibangun, *max_depth* yang mengatur kedalaman pohon, *learning_rate* yang mengontrol besarnya pembelajaran pada setiap iterasi, serta *subsample* dan *colsample_bytree* yang digunakan untuk meningkatkan kemampuan generalisasi model. Oleh karena itu, proses *hyperparameter tuning* sering dilakukan untuk memperoleh kombinasi parameter yang menghasilkan performa terbaik.

Karena tingkat akurasinya yang tinggi dan kemampuannya dalam menangani data yang kompleks, XGBoost menjadi salah satu algoritma yang paling banyak digunakan dalam penelitian maupun kompetisi machine learning. Pada penelitian ini, XGBoost Regression digunakan untuk memprediksi biaya asuransi kesehatan (*charges*) berdasarkan karakteristik peserta asuransi dan dibandingkan dengan algoritma lainnya untuk menentukan model dengan performa prediksi terbaik.

2.3.8 Hyperparameter Tuning

Hyperparameter tuning merupakan proses optimasi parameter model untuk memperoleh performa yang lebih baik. Berbeda dengan parameter model yang dipelajari secara otomatis selama proses pelatihan, hyperparameter harus ditentukan sebelum model dilatih.

Setiap algoritma machine learning memiliki hyperparameter yang berbeda. Sebagai contoh, pada Decision Tree terdapat parameter *max_depth*, sedangkan pada Random Forest terdapat parameter *n_estimators*. Pemilihan nilai hyperparameter yang tepat dapat meningkatkan akurasi model dan mengurangi risiko *overfitting* maupun *underfitting*.

Pada penelitian ini, proses hyperparameter tuning dilakukan menggunakan metode Grid Search Cross Validation (GridSearchCV). Metode ini bekerja dengan menguji berbagai kombinasi hyperparameter dan memilih kombinasi yang menghasilkan performa terbaik berdasarkan metrik evaluasi yang digunakan.

2.3.9 Evaluasi Model

Evaluasi model merupakan tahapan yang dilakukan untuk mengukur kemampuan model dalam menghasilkan prediksi yang akurat. Pada penelitian ini digunakan beberapa metrik evaluasi yang umum digunakan pada permasalahan regresi, yaitu Mean Absolute Error (MAE), Root Mean Squared Error (RMSE), dan Coefficient of Determination (R^2).

a. Mean Absolute Error (MAE)

Mean Absolute Error (MAE) merupakan metrik yang digunakan untuk mengukur rata-rata selisih absolut antara nilai aktual dan nilai prediksi. Nilai MAE menunjukkan seberapa besar kesalahan prediksi yang dihasilkan model tanpa memperhatikan arah kesalahan.

$$MAE = (1/n) \sum |y_i - \hat{y}_i|$$

Keterangan:

- MAE = Mean Absolute Error
- n = jumlah observasi
- y_i = nilai aktual pada observasi ke-i
- $\hat{y}_i$ = nilai prediksi pada observasi ke-i

Semakin kecil nilai MAE, semakin dekat hasil prediksi model terhadap nilai aktual sehingga performa model dianggap semakin baik.

b. Root Mean Squared Error (RMSE)

Root Mean Squared Error (RMSE) digunakan untuk mengukur besarnya kesalahan prediksi dengan memberikan penalti yang lebih besar terhadap kesalahan yang bernilai tinggi. Oleh karena itu, RMSE lebih sensitif terhadap keberadaan error yang besar dibandingkan MAE.

$$RMSE = \sqrt{[(1/n)\sum(y_i - \hat{y}_i)^2]}$$

Keterangan:

- RMSE = Root Mean Squared Error
- n = jumlah observasi
- y_i = nilai aktual pada observasi ke-i
- $\hat{y}_i$ = nilai prediksi pada observasi ke-i

Nilai RMSE yang lebih kecil menunjukkan bahwa model memiliki tingkat kesalahan prediksi yang lebih rendah dan kemampuan prediksi yang lebih baik.

c. Coefficient of Determination (R^2)

Coefficient of Determination atau R^2 merupakan ukuran yang digunakan untuk mengetahui seberapa besar variasi data target yang dapat dijelaskan oleh model.

$$R^2 = 1 - [\sum(y_i - \hat{y}_i)^2 / \sum(y_i - \bar{y})^2]$$

Keterangan:

- R^2 = Coefficient of Determination
- y_i = nilai aktual pada observasi ke-i
- $\hat{y}_i$ = nilai prediksi pada observasi ke-i
- $\bar{y}$ = rata-rata nilai aktual

Nilai R^2 berada pada rentang 0 hingga 1. Semakin mendekati 1, semakin besar proporsi variasi data yang dapat dijelaskan oleh model. Sebaliknya, nilai yang mendekati 0 menunjukkan bahwa model kurang mampu menjelaskan variasi data target.

Dalam penelitian ini, kombinasi nilai MAE yang rendah, RMSE yang rendah, dan R^2 yang tinggi digunakan sebagai indikator untuk menentukan model terbaik dalam memprediksi biaya asuransi kesehatan.

BAB III

METODOLOGI

3.1 Alur Penelitian

Penelitian ini dilakukan melalui serangkaian tahapan yang terstruktur untuk membangun model machine learning dalam memprediksi biaya asuransi kesehatan. Tahapan penelitian diawali dengan pengumpulan dataset yang berisi informasi karakteristik peserta asuransi, seperti usia, jenis kelamin, indeks massa tubuh (BMI), jumlah anak, status perokok, wilayah tempat tinggal, serta biaya asuransi yang menjadi variabel target. Setelah data diperoleh, dilakukan Exploratory Data Analysis (EDA) untuk memahami karakteristik data melalui analisis statistik deskriptif dan berbagai visualisasi. Tahap ini bertujuan untuk mengidentifikasi pola data, hubungan antar variabel, keberadaan missing value, data duplikat, maupun outlier yang dapat memengaruhi proses pemodelan.

Selanjutnya dilakukan tahap preprocessing data untuk mempersiapkan data agar sesuai dengan kebutuhan algoritma machine learning. Pada tahap ini dilakukan penghapusan data duplikat, transformasi variabel kategorik menjadi numerik menggunakan teknik encoding, serta standarisasi data menggunakan metode scaling. Setelah data berada dalam kondisi yang optimal, dilakukan feature engineering melalui pembuatan fitur baru yang merepresentasikan interaksi antara variabel BMI dan usia. Fitur tambahan ini diharapkan dapat meningkatkan kemampuan model dalam menangkap pola yang memengaruhi biaya asuransi kesehatan.

Data yang telah diproses kemudian dibagi menjadi data latih dan data uji dengan proporsi 80:20. Data latih digunakan untuk membangun model, sedangkan data uji digunakan untuk mengevaluasi kemampuan model dalam melakukan prediksi pada data yang belum pernah dilihat sebelumnya. Pada tahap pemodelan digunakan beberapa algoritma regresi, yaitu Linear Regression sebagai model baseline, K-Nearest Neighbor (KNN), Random Forest Regressor, dan XGBoost Regressor. Penggunaan beberapa model bertujuan untuk membandingkan performa masing-masing algoritma sehingga dapat dipilih model yang paling sesuai dengan karakteristik data.

Untuk meningkatkan performa model, dilakukan proses hyperparameter tuning pada algoritma XGBoost menggunakan metode GridSearchCV. Proses ini bertujuan untuk menemukan kombinasi parameter terbaik yang mampu menghasilkan kinerja model yang optimal. Selanjutnya seluruh model dievaluasi menggunakan metrik Mean Absolute Error (MAE), Root Mean Square Error (RMSE), dan Coefficient of Determination (R^2). Hasil evaluasi kemudian dibandingkan untuk menentukan model terbaik.

Tahap terakhir adalah interpretasi hasil model melalui analisis feature importance guna mengidentifikasi faktor-faktor yang paling berpengaruh terhadap biaya asuransi kesehatan. Berdasarkan hasil interpretasi tersebut, dapat diperoleh pemahaman yang lebih mendalam mengenai karakteristik peserta asuransi yang berkontribusi terhadap besarnya biaya asuransi, sehingga hasil penelitian tidak hanya memberikan model prediksi yang baik tetapi juga menghasilkan informasi yang bermanfaat untuk pengambilan keputusan.

3.2 Exploratory Data Analysis (EDA)

Exploratory Data Analysis (EDA) merupakan tahapan awal dalam proses machine learning yang bertujuan untuk memahami karakteristik dataset sebelum dilakukan pemodelan. Melalui EDA, peneliti dapat memperoleh gambaran umum mengenai struktur data, distribusi variabel, hubungan antar variabel, serta mengidentifikasi permasalahan yang mungkin terdapat pada data seperti missing value, data duplikat, dan outlier. Tahap ini sangat penting karena kualitas analisis pada tahap awal akan memengaruhi performa model yang dibangun pada tahap selanjutnya.

Pada penelitian ini, EDA dilakukan menggunakan analisis statistik deskriptif dan berbagai teknik visualisasi data untuk memahami pola serta karakteristik yang terdapat pada dataset biaya asuransi kesehatan.

3.2.1 Statistik Deskriptif

Analisis statistik deskriptif dilakukan untuk memberikan gambaran umum mengenai karakteristik data yang digunakan dalam penelitian. Dataset terdiri atas 1.338 observasi dan 7 variabel yang meliputi age, sex, bmi, children, smoker, region, dan charges sebagai variabel target.

Berdasarkan hasil analisis statistik deskriptif diperoleh bahwa rata-rata usia peserta asuransi adalah sekitar 39 tahun. Variabel BMI memiliki rata-rata sekitar 31 tahun yang menunjukkan bahwa sebagian besar peserta berada pada kategori overweight hingga obesitas ringan. Rata-rata jumlah anak yang ditanggung peserta asuransi adalah sekitar 1 anak. Sementara itu, rata-rata biaya asuransi kesehatan (charges) sebesar 13.270,42 dengan nilai yang cukup bervariasi antar individu.

Variasi yang cukup besar pada variabel charges mengindikasikan adanya perbedaan biaya asuransi yang signifikan antar peserta. Hal ini menunjukkan bahwa terdapat faktor-faktor tertentu yang memiliki pengaruh kuat terhadap besarnya biaya asuransi kesehatan.

Selain variabel numerik, dilakukan pula analisis terhadap variabel kategorik. Distribusi jenis kelamin menunjukkan jumlah peserta laki-laki sebanyak 676 orang dan perempuan sebanyak 662 orang sehingga distribusinya relatif seimbang. Pada variabel smoker, mayoritas peserta merupakan bukan perokok dengan jumlah 1.064 orang, sedangkan peserta yang berstatus perokok sebanyak 274 orang. Distribusi wilayah tempat tinggal juga relatif merata pada keempat region yang tersedia dalam dataset.

3.2.2 Analisis Missing Value

Pemeriksaan missing value dilakukan untuk mengetahui apakah terdapat data yang hilang pada setiap variabel. Data yang hilang dapat menyebabkan penurunan kualitas model karena informasi yang tersedia menjadi tidak lengkap. Hasil pemeriksaan menunjukkan bahwa seluruh variabel dalam dataset memiliki jumlah missing value sebesar nol. Dengan demikian, dataset dapat dikatakan memiliki kualitas yang baik karena tidak terdapat data yang hilang dan tidak diperlukan proses imputasi maupun penghapusan observasi akibat missing value. Keberadaan data yang lengkap memberikan keuntungan dalam proses pemodelan karena seluruh informasi yang tersedia dapat dimanfaatkan secara optimal tanpa perlu melakukan estimasi nilai pengganti.

3.2.3 Analisis Data Duplikat

Selain missing value, dilakukan pula pemeriksaan terhadap data duplikat. Data duplikat merupakan observasi yang muncul lebih dari satu kali dan dapat menyebabkan bias pada model karena suatu informasi memperoleh bobot yang lebih besar dibandingkan observasi lainnya.

Hasil analisis menunjukkan bahwa terdapat satu data duplikat pada dataset. Meskipun jumlahnya relatif kecil, data tersebut tetap dihapus pada tahap preprocessing untuk menjaga kualitas data dan menghindari kemungkinan bias dalam proses pembelajaran model. Dengan dihilangkannya data duplikat, setiap observasi yang digunakan dalam penelitian merepresentasikan informasi yang unik dan independen.

3.2.4 Analisis Distribusi Variabel Numerik

Analisis distribusi variabel numerik dilakukan untuk memahami pola penyebaran data, kecenderungan nilai, serta mendeteksi adanya ketidakseimbangan distribusi maupun nilai ekstrem pada setiap variabel. Analisis ini dilakukan menggunakan visualisasi histogram yang memungkinkan peneliti untuk melihat bentuk distribusi masing-masing variabel secara lebih jelas. Variabel numerik yang dianalisis dalam penelitian ini meliputi *age*, *bmi*, *children*, dan *charges*.

a. Distribusi Age

Variabel *age* merepresentasikan usia peserta asuransi kesehatan. Berdasarkan histogram yang dihasilkan, distribusi usia peserta menunjukkan penyebaran yang cukup merata pada rentang usia dewasa muda hingga usia lanjut. Tidak terlihat adanya dominasi yang sangat besar pada kelompok usia tertentu.

Pola distribusi yang relatif merata ini menunjukkan bahwa dataset memiliki representasi usia yang cukup beragam sehingga model dapat mempelajari karakteristik peserta asuransi dari berbagai kelompok usia. Keragaman usia ini penting karena usia merupakan salah satu faktor yang secara teoritis memiliki hubungan dengan tingkat risiko kesehatan seseorang.

Secara umum, semakin bertambah usia seseorang maka risiko kesehatan yang dimiliki juga cenderung meningkat. Oleh karena itu, distribusi usia yang bervariasi memungkinkan model untuk mengidentifikasi pola hubungan antara usia dan biaya asuransi secara lebih baik.

b. Distribusi BMI

Variabel BMI digunakan untuk menggambarkan kondisi fisik seseorang berdasarkan perbandingan antara berat badan dan tinggi badan. Histogram variabel BMI menunjukkan bahwa sebagian besar data terkonsentrasi pada rentang nilai sekitar 25 hingga 35.

Pola distribusi tersebut menunjukkan bahwa mayoritas peserta asuransi dalam dataset berada pada kategori overweight hingga obesitas ringan. Selain itu, terdapat beberapa observasi dengan nilai BMI yang relatif tinggi dibandingkan mayoritas data.

Kondisi ini menunjukkan adanya variasi tingkat kesehatan fisik peserta asuransi yang dapat berpengaruh terhadap biaya asuransi kesehatan. Individu dengan BMI yang lebih tinggi umumnya memiliki risiko kesehatan yang lebih besar sehingga berpotensi menghasilkan biaya asuransi yang lebih tinggi.

c. Distribusi Children

Variabel children menunjukkan jumlah anak yang menjadi tanggungan peserta asuransi. Hasil histogram menunjukkan bahwa sebagian besar peserta memiliki jumlah anak antara 0 hingga 2 orang.

Frekuensi observasi semakin menurun seiring bertambahnya jumlah anak yang dimiliki peserta. Hal ini menunjukkan bahwa peserta dengan jumlah anak yang banyak relatif lebih sedikit dibandingkan peserta dengan jumlah anak yang sedikit.

Distribusi ini mencerminkan kondisi yang umum ditemukan pada masyarakat, di mana sebagian besar keluarga memiliki jumlah anak yang tidak terlalu banyak. Meskipun demikian, variabel ini tetap berpotensi memberikan kontribusi terhadap biaya asuransi karena semakin banyak anggota keluarga yang ditanggung dapat meningkatkan kebutuhan perlindungan kesehatan.

d. Distribusi Charges

Variabel charges merupakan variabel target yang merepresentasikan biaya asuransi kesehatan yang harus dibayarkan oleh peserta. Berdasarkan histogram yang dihasilkan, distribusi

charges menunjukkan pola yang tidak simetris dan cenderung menceng ke kanan (*right-skewed distribution*).

Sebagian besar peserta memiliki biaya asuransi yang relatif rendah hingga sedang, sedangkan sejumlah kecil peserta memiliki biaya asuransi yang sangat tinggi. Kondisi ini menyebabkan terbentuknya ekor distribusi yang panjang pada sisi kanan histogram.

Pola distribusi seperti ini umum ditemukan pada data biaya kesehatan karena terdapat kelompok individu dengan risiko kesehatan yang lebih tinggi, misalnya akibat usia lanjut, kondisi obesitas, atau kebiasaan merokok. Kelompok tersebut biasanya memerlukan biaya perlindungan kesehatan yang lebih besar dibandingkan peserta lainnya.

Distribusi target yang tidak normal ini juga mengindikasikan bahwa hubungan antara variabel prediktor dan target kemungkinan bersifat kompleks dan tidak sepenuhnya linear. Oleh karena itu, selain model linear, diperlukan algoritma machine learning yang mampu menangkap hubungan non-linear seperti Random Forest dan XGBoost.

3.2.5 Analisis Outlier

Analisis outlier dilakukan menggunakan boxplot untuk mengidentifikasi nilai-nilai ekstrem yang berbeda jauh dari mayoritas data. Hasil visualisasi menunjukkan bahwa variabel BMI memiliki beberapa nilai yang berada di luar rentang normal. Selain itu, variabel charges menunjukkan jumlah outlier yang cukup banyak dengan nilai biaya asuransi yang sangat tinggi.

Keberadaan outlier pada biaya asuransi dapat disebabkan oleh kondisi kesehatan tertentu, faktor usia yang tinggi, maupun kebiasaan merokok yang meningkatkan risiko kesehatan seseorang. Oleh karena itu, outlier pada penelitian ini tidak dihapus karena masih merepresentasikan kondisi nyata yang terjadi pada populasi peserta asuransi. Menghapus outlier tersebut justru berpotensi menghilangkan informasi penting yang diperlukan model untuk mempelajari pola biaya asuransi pada kelompok berisiko tinggi.

3.2.6 Analisis Hubungan Variabel Numerik terhadap Target

Menganalisis hubungan antara variabel numerik dengan variabel target, yaitu **charges** (biaya asuransi kesehatan). Analisis ini dilakukan menggunakan **scatter plot** untuk mengetahui

pola hubungan, arah hubungan, serta kekuatan pengaruh masing-masing variabel terhadap biaya asuransi.

Melalui scatter plot, dapat diamati apakah suatu variabel memiliki hubungan positif, negatif, atau bahkan tidak memiliki hubungan yang jelas terhadap variabel target. Informasi ini sangat penting karena dapat memberikan gambaran awal mengenai variabel-variabel yang berpotensi menjadi prediktor utama dalam proses pemodelan machine learning.

a. Hubungan Variabel Age terhadap Charges

Berdasarkan hasil visualisasi scatter plot, terlihat adanya kecenderungan hubungan positif antara variabel age dan charges. Semakin tinggi usia peserta asuransi, biaya asuransi yang dibayarkan cenderung semakin besar.

Fenomena ini dapat dijelaskan karena peningkatan usia umumnya diikuti dengan meningkatnya risiko kesehatan seseorang. Individu yang berusia lebih tua memiliki kemungkinan lebih besar mengalami penyakit kronis atau memerlukan layanan kesehatan yang lebih intensif dibandingkan individu yang lebih muda. Oleh karena itu, perusahaan asuransi biasanya menetapkan biaya asuransi yang lebih tinggi pada kelompok usia lanjut.

Meskipun demikian, penyebaran titik pada grafik masih cukup luas sehingga menunjukkan bahwa biaya asuransi tidak hanya dipengaruhi oleh usia, tetapi juga dipengaruhi oleh faktor lain seperti indeks massa tubuh, status merokok, dan kondisi kesehatan lainnya.

b. Hubungan Variabel BMI terhadap Charges

Scatter plot antara variabel BMI dan charges menunjukkan adanya kecenderungan hubungan positif. Individu dengan nilai BMI yang lebih tinggi cenderung memiliki biaya asuransi yang lebih besar dibandingkan individu dengan BMI yang lebih rendah.

BMI merupakan indikator yang menggambarkan kondisi berat badan seseorang terhadap tinggi badannya. Nilai BMI yang tinggi sering dikaitkan dengan berbagai risiko kesehatan seperti obesitas, diabetes, hipertensi, dan penyakit jantung. Risiko kesehatan tersebut dapat meningkatkan kemungkinan klaim asuransi sehingga perusahaan asuransi mengenakan biaya yang lebih tinggi kepada peserta dengan BMI yang besar.

Selain itu, terlihat bahwa beberapa individu dengan BMI tinggi memiliki biaya asuransi yang sangat besar. Kondisi ini menunjukkan adanya kemungkinan interaksi antara BMI dan variabel lain yang turut memengaruhi biaya asuransi. Oleh karena itu, pada tahap feature engineering dibuat fitur baru berupa interaksi antara BMI dan usia untuk menangkap hubungan yang lebih kompleks.

c. Hubungan Variabel Children terhadap Charges

Hasil scatter plot antara variabel children dan charges menunjukkan pola hubungan yang relatif lemah. Sebaran titik data terlihat cukup acak tanpa menunjukkan pola peningkatan atau penurunan yang konsisten.

Hal ini menunjukkan bahwa jumlah anak yang ditanggung peserta asuransi bukan merupakan faktor utama yang menentukan besarnya biaya asuransi kesehatan. Meskipun terdapat beberapa peserta dengan jumlah anak yang lebih banyak dan memiliki biaya asuransi yang tinggi, pola tersebut tidak terjadi secara konsisten pada seluruh data.

Dibandingkan dengan variabel age dan BMI, variabel children memiliki kontribusi yang relatif kecil terhadap perubahan biaya asuransi sehingga pengaruhnya terhadap model prediksi diperkirakan tidak sebesar variabel lainnya.

3.2.7 Analisis Distribusi Variabel Kategorik

Selain variabel numerik, analisis juga dilakukan terhadap variabel kategorik yang terdiri atas sex, smoker, dan region. Analisis ini bertujuan untuk mengetahui distribusi masing-masing kategori dalam dataset sehingga dapat memberikan gambaran mengenai karakteristik populasi peserta asuransi.

a. Variabel Sex

Hasil analisis menunjukkan bahwa jumlah peserta laki-laki sebanyak 676 orang, sedangkan peserta perempuan sebanyak 662 orang. Distribusi ini menunjukkan bahwa komposisi jenis kelamin dalam dataset relatif seimbang. Kondisi tersebut memberikan keuntungan dalam proses pemodelan karena model tidak akan terlalu dipengaruhi oleh dominasi salah satu kategori jenis

kelamin. Dengan distribusi yang hampir sama, model dapat mempelajari karakteristik kedua kelompok secara proporsional.

b. Variabel Smoker

Variabel smoker menunjukkan bahwa terdapat 1.064 peserta yang tidak merokok dan 274 peserta yang berstatus perokok. Meskipun jumlah perokok lebih sedikit dibandingkan bukan perokok, kondisi ini masih dianggap wajar karena mencerminkan distribusi populasi yang sebenarnya. Perbedaan proporsi tersebut juga memberikan indikasi awal bahwa status merokok dapat menjadi salah satu faktor penting yang memengaruhi biaya asuransi kesehatan.

Kebiasaan merokok diketahui dapat meningkatkan risiko berbagai penyakit serius, seperti kanker paru-paru, penyakit jantung, dan gangguan pernapasan. Oleh karena itu, perusahaan asuransi biasanya menetapkan biaya yang lebih tinggi bagi peserta yang memiliki status perokok.

c. Variabel Region

Variabel region menunjukkan distribusi peserta yang relatif merata pada empat wilayah, yaitu northeast, northwest, southeast, dan southwest. Jumlah peserta pada masing-masing wilayah berkisar antara 324 hingga 364 orang. Distribusi yang cukup merata ini menunjukkan bahwa tidak terdapat dominasi wilayah tertentu dalam dataset sehingga model dapat mempelajari karakteristik biaya asuransi dari berbagai wilayah secara seimbang. Selain itu, distribusi yang merata juga mengurangi kemungkinan bias model terhadap salah satu wilayah tertentu.

3.2.8 Analisis Korelasi Antar Variabel

Analisis korelasi dilakukan untuk mengetahui tingkat hubungan antara variabel-variabel yang terdapat dalam dataset. Korelasi diukur menggunakan matriks korelasi yang divisualisasikan dalam bentuk heatmap sehingga memudahkan interpretasi hubungan antar variabel.

Nilai korelasi berada pada rentang -1 hingga 1. Nilai yang mendekati 1 menunjukkan hubungan positif yang kuat, nilai yang mendekati -1 menunjukkan hubungan negatif yang kuat, sedangkan nilai yang mendekati 0 menunjukkan hubungan yang lemah atau tidak terdapat

hubungan linear. yang signifikan. Berdasarkan heatmap korelasi yang diperoleh, terdapat beberapa temuan penting.

a. Korelasi Variabel Smoker terhadap Charges

Variabel smoker memiliki korelasi positif paling tinggi terhadap **charges** dibandingkan variabel lainnya. Hasil ini menunjukkan bahwa status merokok merupakan faktor yang paling berpengaruh terhadap besarnya biaya asuransi kesehatan.

Peserta yang memiliki kebiasaan merokok cenderung memiliki biaya asuransi yang lebih tinggi karena risiko kesehatan yang dimiliki juga lebih besar. Temuan ini sejalan dengan teori dalam industri asuransi yang menjadikan status merokok sebagai salah satu faktor utama dalam penentuan premi.

b. Korelasi Variabel BMI_Age terhadap Charges

Fitur baru bmi_age yang merupakan hasil perkalian antara BMI dan usia menunjukkan korelasi yang cukup kuat terhadap biaya asuransi. Hasil ini menunjukkan bahwa kombinasi antara usia dan kondisi fisik seseorang mampu memberikan informasi tambahan yang tidak sepenuhnya dapat dijelaskan oleh masing-masing variabel secara terpisah. Temuan ini mengindikasikan bahwa feature engineering yang dilakukan berhasil meningkatkan representasi informasi yang terdapat dalam dataset.

c. Korelasi Variabel Age dan BMI terhadap Charges

Variabel age dan BMI juga menunjukkan korelasi positif terhadap biaya asuransi kesehatan. Meskipun korelasinya tidak sekuat smoker, kedua variabel tersebut tetap memiliki kontribusi yang cukup penting dalam menjelaskan variasi biaya asuransi. Semakin tinggi usia dan BMI seseorang, semakin besar pula kecenderungan biaya asuransi yang harus dibayarkan.

d. Korelasi Variabel Lain

Variabel children, sex, dan region menunjukkan nilai korelasi yang relatif rendah terhadap charges. Hal ini mengindikasikan bahwa pengaruh variabel-variabel tersebut terhadap biaya asuransi tidak sebesar variabel smoker, age, BMI, maupun bmi_age.

3.3 Preprocessing

Preprocessing data merupakan tahapan penting dalam proses machine learning yang bertujuan untuk mempersiapkan data agar berada dalam kondisi optimal sebelum digunakan pada tahap pemodelan. Data yang belum diproses sering kali mengandung berbagai permasalahan, seperti data yang hilang, format data yang tidak sesuai, maupun perbedaan skala antar variabel yang dapat memengaruhi performa model. Oleh karena itu, dilakukan beberapa tahapan preprocessing yang meliputi penanganan missing value, encoding variabel kategorik, scaling data, dan pembagian data menjadi data latih serta data uji.

3.3.1 Penanganan Missing Value

Tahap pertama dalam preprocessing adalah pemeriksaan missing value pada seluruh variabel dataset. Missing value merupakan kondisi ketika suatu observasi tidak memiliki nilai pada variabel tertentu sehingga dapat mengurangi kualitas informasi yang tersedia.

Berdasarkan hasil analisis pada tahap Exploratory Data Analysis (EDA), seluruh variabel dalam dataset memiliki jumlah missing value sebesar nol. Dengan demikian, tidak diperlukan proses penanganan missing value seperti imputasi menggunakan mean, median, mode, maupun penghapusan observasi.

Kondisi ini menunjukkan bahwa dataset yang digunakan memiliki kualitas yang baik karena seluruh data tersedia secara lengkap sehingga dapat langsung digunakan pada tahapan berikutnya tanpa perlu melakukan perbaikan data.

3.3.2 Encoding Variabel Kategorik

Sebagian besar algoritma machine learning hanya dapat memproses data dalam bentuk numerik. Oleh karena itu, variabel kategorik pada dataset perlu diubah terlebih dahulu menjadi representasi numerik melalui proses encoding. Terdapat tiga variabel kategorik, yaitu sex, smoker, dan region.

a. Binary Encoding

Variabel sex dan smoker memiliki dua kategori sehingga dilakukan transformasi menggunakan Binary Encoding.

Encoding Variabel Sex

Kategori	Nilai
Female	0
Male	1

Encoding Variabel Smoker

Kategori	Nilai
No	0
Yes	1

a. One-Hot Encoding

Variabel region memiliki empat kategori, yaitu:

- Northeast
- Northwest
- Southeast
- Southwest

Karena tidak terdapat hubungan urutan antar kategori wilayah, maka digunakan metode One-Hot Encoding. Teknik ini mengubah satu variabel kategorik menjadi beberapa variabel dummy yang bernilai 0 atau 1.

Hasil transformasi menghasilkan tiga variabel baru, yaitu:

- region_northwest
- region_southeast
- Region_southwest

Sementara kategori northeast digunakan sebagai kategori referensi (baseline). Penggunaan One-Hot Encoding bertujuan untuk menghindari kesalahan interpretasi model yang mungkin menganggap adanya hubungan ordinal antar wilayah apabila dilakukan label encoding biasa.

3.3.3 Scalling Data

Tahap berikutnya adalah standarisasi data menggunakan metode StandardScaler. Scaling merupakan proses transformasi data untuk menyamakan skala antar variabel sehingga setiap fitur memiliki kontribusi yang seimbang dalam proses pembelajaran model. Variabel seperti age, bmi, dan charges memiliki rentang nilai yang berbeda cukup jauh. Jika tidak dilakukan scaling, variabel dengan nilai yang lebih besar dapat mendominasi proses pembelajaran model.

Metode StandardScaler melakukan transformasi berdasarkan rumus :

$$\square = \frac{\square - \square}{\square}$$

Dengan keterangan :

- $\square$ = nilai data
- μ = rata-rata data
- σ = standar deviasi

Hasil transformasi menghasilkan data dengan rata-rata mendekati 0 dan standar deviasi mendekati 1. Proses scaling sangat penting terutama pada algoritma yang berbasis jarak seperti K-Nearest Neighbor (KNN), karena perhitungan jarak sangat dipengaruhi oleh besarnya skala data. Selain itu, scaling juga membantu mempercepat proses konvergensi pada beberapa algoritma machine learning.

3.3.4 Pembagian Data Train-Test

Setelah seluruh data selesai diproses, dataset dibagi menjadi dua bagian yaitu data latih (training set) dan data uji (testing set). Pembagian data dilakukan menggunakan fungsi `train_test_split()` dengan proporsi yaitu training data = 80% dan testing data = 20%

Proporsi ini dipilih karena mampu memberikan jumlah data yang cukup besar untuk proses pelatihan model sekaligus menyediakan data yang memadai untuk proses evaluasi. Data latih digunakan untuk membangun model machine learning, sedangkan data uji digunakan untuk

mengukur kemampuan model dalam melakukan prediksi terhadap data yang belum pernah dilihat sebelumnya.

3.4 Feature Engineering & Selection

Feature engineering merupakan proses menciptakan fitur baru dari data yang sudah ada guna meningkatkan kemampuan model dalam menangkap pola yang terdapat pada dataset. Selain itu, dilakukan pula feature selection untuk menentukan fitur-fitur yang relevan dalam proses pemodelan.

3.4.1 Pembuatan Fitur Baru (Feature Engineering)

Pada penelitian ini dilakukan pembuatan fitur baru berupa interaksi antara variabel BMI dan Age. Fitur tersebut dinamakan:

$$\text{BMI_Age} = \text{BMI} \times \text{Age}$$

Fitur ini dibuat karena secara teoritis risiko kesehatan seseorang tidak hanya dipengaruhi oleh usia maupun BMI secara terpisah, tetapi juga kombinasi keduanya. Dengan adanya fitur interaksi ini, model diharapkan mampu menangkap hubungan non-linear yang lebih kompleks antara kondisi fisik dan usia terhadap biaya asuransi kesehatan.

Hasil analisis korelasi menunjukkan bahwa fitur BMI_Age memiliki hubungan yang cukup kuat terhadap variabel target sehingga berpotensi meningkatkan performa model.

3.4.2 Seleksi Fitur (Feature Selection)

Seleksi fitur dilakukan untuk mengetahui tingkat kontribusi masing-masing variabel terhadap prediksi biaya asuransi kesehatan. Pada penelitian ini seleksi fitur dilakukan melalui:

1. Analisis Korelasi (Correlation Analysis)
2. Feature Importance pada model Random Forest

Berdasarkan hasil analisis, seluruh fitur memiliki kontribusi terhadap model sehingga tidak ada fitur yang dihapus. Fitur yang digunakan pada proses pemodelan meliputi:

- age

- sex
- bmi
- children
- smoker
- region_northwest
- region_southeast
- region_southwest
- bmi_age

Penggunaan seluruh fitur tersebut bertujuan untuk mempertahankan informasi yang tersedia sehingga model dapat mempelajari hubungan antar variabel secara lebih optimal.

3.5 Modeling

Tahap pemodelan dilakukan untuk membangun model machine learning yang mampu memprediksi biaya asuransi kesehatan berdasarkan karakteristik peserta asuransi. Karena variabel target berupa nilai numerik kontinu (charges), maka penelitian ini termasuk ke dalam kasus **regresi (regression problem)**. Beberapa algoritma digunakan sebagai model pembanding untuk memperoleh model dengan performa terbaik.

3.5.1 Linear Regression

Linear Regression merupakan model regresi yang digunakan sebagai baseline model dalam penelitian ini. Model ini mengasumsikan bahwa terdapat hubungan linear antara variabel independen dan variabel dependen. Persamaan umum Linear Regression adalah :

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n$$

Model ini mudah diinterpretasikan dan memiliki proses pelatihan yang relatif cepat. Namun, kemampuan model dalam menangkap hubungan non-linear cukup terbatas.

3.5.2 Random Forest Regressor

Random Forest Regressor merupakan metode ensemble learning yang dibangun dari kumpulan decision tree. Setiap pohon keputusan dibangun menggunakan sampel data yang

berbeda, kemudian hasil prediksi seluruh pohon digabungkan melalui proses averaging untuk menghasilkan prediksi akhir.

Keunggulan Random Forest meliputi:

- Mampu menangkap hubungan non-linear.
- Lebih tahan terhadap overfitting dibandingkan decision tree tunggal.
- Mampu mengukur tingkat kepentingan fitur (feature importance).
- Memiliki performa yang baik pada data dengan karakteristik kompleks.

3.5.3 XGBoost Regressor

Extreme Gradient Boosting (XGBoost) merupakan algoritma boosting yang membangun model secara bertahap dengan memperbaiki kesalahan model sebelumnya. Setiap pohon keputusan baru dibuat untuk mempelajari residual atau kesalahan prediksi dari model sebelumnya sehingga akurasi model meningkat secara bertahap. Keunggulan XGBoost antara lain:

- Akurasi tinggi.
- Efisien secara komputasi.
- Mampu menangani hubungan non-linear.
- Memiliki kemampuan regularisasi yang baik sehingga mengurangi risiko overfitting.

Karena performanya yang sangat baik pada berbagai kompetisi machine learning, XGBoost sering digunakan sebagai salah satu algoritma terbaik untuk kasus regresi maupun klasifikasi.

3.6 Hyperparameter Tuning

Hyperparameter tuning merupakan proses optimasi parameter model yang dilakukan sebelum proses pelatihan model untuk memperoleh performa prediksi yang lebih baik. Berbeda dengan parameter model yang dipelajari secara otomatis selama proses training, hyperparameter harus ditentukan terlebih dahulu oleh pengguna. Pemilihan hyperparameter yang tepat dapat meningkatkan akurasi model, mengurangi risiko overfitting, serta meningkatkan kemampuan generalisasi model terhadap data baru.

Pada penelitian ini, proses hyperparameter tuning dilakukan pada model Random Forest Regressor karena model tersebut menunjukkan performa yang menjanjikan dalam memprediksi biaya asuransi kesehatan. Metode yang digunakan adalah GridSearchCV, yaitu teknik pencarian hyperparameter yang mencoba seluruh kombinasi parameter yang telah ditentukan untuk menemukan kombinasi terbaik berdasarkan hasil evaluasi cross-validation.

3.6.1 Metode GridSearchCV

GridSearchCV bekerja dengan melakukan pencarian secara menyeluruh (*exhaustive search*) terhadap seluruh kombinasi hyperparameter yang tersedia pada parameter grid. Setiap kombinasi parameter akan diuji menggunakan teknik cross-validation sehingga diperoleh model dengan performa terbaik.

Keunggulan GridSearchCV adalah kemampuannya dalam menemukan kombinasi parameter optimal secara sistematis karena seluruh kemungkinan kombinasi akan dievaluasi. Namun demikian, metode ini memerlukan waktu komputasi yang lebih besar dibandingkan metode pencarian acak (*Randomized Search*) karena seluruh kombinasi parameter harus dicoba.

Pada penelitian ini digunakan 5-Fold Cross Validation, sehingga setiap kombinasi parameter dievaluasi sebanyak lima kali pada pembagian data yang berbeda. Pendekatan ini bertujuan untuk menghasilkan estimasi performa model yang lebih stabil dan mengurangi kemungkinan bias akibat pembagian data tertentu.

3.6.2 Parameter yang Diuji

Proses tuning dilakukan dengan menguji beberapa kombinasi hyperparameter Random Forest Regressor sebagai berikut:

Hyperparameter	Nilai yang diuji
n_estimators	100, 200, 300
max_depth	3, 4, 5
max_samples_split	2, 5, 10

Min_samples_leaf	1, 2, 4
------------------	---------

Penjelasan masing-masing parameter adalah sebagai berikut:

a. n_estimators

Parameter ini menentukan jumlah pohon keputusan (*decision tree*) yang dibangun dalam Random Forest.

- Semakin banyak pohon yang digunakan, model cenderung menjadi lebih stabil dan akurat.
- Namun jumlah pohon yang terlalu banyak dapat meningkatkan waktu komputasi.

Pada penelitian ini diuji tiga nilai yaitu 100, 200, dan 300 pohon.

b. max_depth

Parameter ini menentukan kedalaman maksimum setiap pohon keputusan.

- Nilai yang lebih kecil menghasilkan model yang lebih sederhana dan mengurangi risiko overfitting.
- Nilai yang lebih besar memungkinkan model menangkap pola yang lebih kompleks.

Nilai yang diuji adalah 3, 4, dan 5.

c. min_samples_split

Parameter ini menentukan jumlah minimum sampel yang diperlukan untuk membagi suatu node menjadi cabang baru.

- Nilai yang kecil memungkinkan pohon tumbuh lebih kompleks.
- Nilai yang besar membantu mengurangi overfitting.

Nilai yang diuji adalah 2, 5, dan 10.

d. min_samples_leaf

Parameter ini menentukan jumlah minimum sampel yang harus terdapat pada node akhir (*leaf node*).

- Nilai yang lebih besar menghasilkan model yang lebih sederhana.
- Nilai yang lebih kecil memungkinkan model menangkap pola data yang lebih detail.

Nilai yang diuji adalah 1, 2, dan 4.

3.6.3 Jumlah Kombinasi Parameter

Berdasarkan parameter yang diuji, jumlah kombinasi yang dievaluasi oleh GridSearchCV adalah:

$$3 \times 3 \times 3 \times 3 = 81$$

kombinasi hyperparameter.

Karena setiap kombinasi diuji menggunakan 5-Fold Cross Validation, maka total proses pelatihan model yang dilakukan adalah:

$$81 \times 5 = 405$$

kali pelatihan model.

Jumlah tersebut menunjukkan bahwa proses tuning dilakukan secara menyeluruh sehingga kombinasi parameter terbaik dapat ditemukan dengan lebih akurat.

3.6.4 Hasil Hyperparameter Tuning

Hasil GridSearchCV menunjukkan bahwa model Random Forest yang telah dioptimasi menghasilkan performa yang lebih baik dibandingkan model Random Forest dengan parameter default. Model hasil tuning mampu menghasilkan nilai koefisien determinasi (R^2) yang lebih tinggi serta nilai kesalahan prediksi (MAE dan RMSE) yang lebih rendah.

Peningkatan performa tersebut menunjukkan bahwa pemilihan hyperparameter yang tepat berperan penting dalam meningkatkan kemampuan model dalam menangkap hubungan antara karakteristik peserta asuransi dan biaya asuransi kesehatan. Oleh karena itu, model Tuned Random

Forest Regressor dipilih sebagai model terbaik dan digunakan pada tahap evaluasi serta interpretasi hasil penelitian.

BAB IV


HASIL DAN PEMBAHASAN

4.1 Hasil Exploratory Data Analysis (EDA)

Eksplorasi data dilakukan untuk memahami karakteristik dataset sebelum proses pemodelan. Dataset yang digunakan adalah insurance.csv yang memuat data biaya asuransi kesehatan individu dengan 1.338 baris dan 7 kolom, yaitu age, sex, bmi, children, smoker, region, dan charges sebagai variabel target.

4.1.1 Statistik Deskriptif

Berdasarkan hasil `df.describe()`, diperoleh ringkasan statistik sebagai berikut. Variabel age memiliki rata-rata 39,21 tahun dengan rentang 18 hingga 64 tahun. Variabel bmi rata-rata sebesar 30,66 yang tergolong kategori overweight menurut standar WHO. Variabel children rata-rata 1,09 tanggungan. Variabel target charges memiliki rata-rata \$13.270,42 dengan standar deviasi yang tinggi (\$12.110,01), mengindikasikan variasi biaya yang besar antar individu.




Gambar 4.1 Histogram Distribusi Variabel Numerik Dataset Insurance

4.1.2 Kualitas Data


Pemeriksaan missing value menunjukkan tidak ada nilai kosong pada seluruh kolom ($\text{df.isnull().sum() = 0}$ untuk semua kolom), sehingga tidak diperlukan proses imputasi. Namun ditemukan 1 baris duplikat yang perlu ditangani pada tahap preprocessing.

4.1.3 Distribusi Variabel Kategorik

Dari hasil `value_counts()`, distribusi variabel kategorik adalah sebagai berikut. Variabel sex terdistribusi relatif seimbang dengan 676 laki-laki dan 662 perempuan. Variabel smoker bersifat imbalanced dengan 1.064 non-perokok (79,5%) dan 274 perokok (20,5%), namun kondisi ini mencerminkan distribusi populasi nyata.



Gambar 4.2 Distribusi Frekuensi Variabel sex




Gambar 4.3 Distribusi Frekuensi Variabel smoker

Variabel region terdistribusi merata di empat wilayah dengan rentang 324–364 data per wilayah.


4.1.4 Distribusi Variabel Numerik

Berdasarkan histogram dan boxplot, variabel charges menunjukkan distribusi right-skewed dengan sebagian besar nilai terkonsentrasi di bawah \$20.000, namun terdapat sejumlah nilai ekstrem yang mencapai lebih dari \$60.000.




Gambar 4.4 Distribusi Variabel Target (Charges) dengan Kurva KDE

Variabel bmi memiliki beberapa outlier di sisi kanan (nilai BMI di atas 47), sedangkan age tidak menunjukkan outlier yang signifikan.



Gambar 4.5 Boxplot Variabel Age



Gambar 4.6 Boxplot Variabel Age

4.2 Hasil Preprocessing

Preprocessing dilakukan dalam dua tahap utama, yaitu pembersihan data dan transformasi fitur.

4.2.1 Penghapusan Duplikat

Satu baris data duplikat dihapus menggunakan `df.drop_duplicates()`, sehingga jumlah data berkurang dari 1.338 menjadi 1.337 baris.

4.2.2 Encoding Variabel Kategorik

Variabel `sex` dan `smoker` yang bersifat biner dikonversi menggunakan binary encoding secara manual melalui `.map()`. Variabel `sex` dikodekan menjadi 0 (female) dan 1 (male), sedangkan `smoker` dikodekan menjadi 0 (no) dan 1 (yes).


Variabel `region` yang memiliki empat kategori dikonversi menggunakan One-Hot Encoding melalui `pd.get_dummies()` dengan parameter `drop_first=True`. Kategori `region_northeast` dijadikan referensi (dihilangkan) untuk menghindari dummy variable trap, sehingga menghasilkan tiga kolom baru: `region_northwest`, `region_southeast`, dan `region_southwest`.

4.2.3 Feature Engineering

Dibuat satu fitur baru berupa variabel interaksi `bmi_age` yang merupakan hasil perkalian antara `bmi` dan `age`:

$$df['bmi_age'] = df['bmi'] \times df['age']$$

Fitur ini dibuat berdasarkan asumsi bahwa individu berusia tua dengan BMI tinggi cenderung memiliki risiko kesehatan yang lebih besar, sehingga kedua variabel tersebut tidak bekerja secara independen terhadap biaya klaim. Dari heatmap korelasi, `bmi_age` memiliki korelasi sebesar 0,33 terhadap `charges`, lebih tinggi dibandingkan `bmi` (0,20) maupun `age` (0,30) secara terpisah, yang membuktikan manfaat penambahan fitur interaksi ini.



Gambar 4.7 Heatmap Korelasi Antar Variabel Setelah Feature Engineering

4.2.4 Pembagian Data dan Standarisasi

Data dibagi menjadi data latih (80%) dan data uji (20%) menggunakan `train_test_split` dengan `random_state=42`, menghasilkan 1.069 data latih dan 268 data uji. Standarisasi menggunakan `StandardScaler` hanya diterapkan pada data yang akan digunakan model KNN, karena KNN sensitif terhadap perbedaan skala antar fitur. Model berbasis pohon (Random Forest dan XGBoost) menggunakan data mentah tanpa standarisasi karena tidak dipengaruhi oleh skala fitur. Total fitur akhir yang digunakan berjumlah 9 kolom: age, sex, bmi, children, smoker, region_northwest, region_southeast, region_southwest, dan bmi_age.

4.3 Hasil Pemodelan


Pemodelan dilakukan menggunakan empat algoritma, yaitu Linear Regression sebagai baseline, K-Nearest Neighbors (KNN), Random Forest, dan XGBoost. Selanjutnya dilakukan hyperparameter tuning pada model terbaik.

4.3.1 Linear Regression (Baseline)

Model Linear Regression dilatih langsung pada data latih tanpa standarisasi. Hasil evaluasi pada data uji menunjukkan MAE sebesar \$4.176,92, RMSE sebesar \$5.956,45, dan R^2 sebesar 0,8069. Nilai R^2 ini mengindikasikan bahwa model mampu menjelaskan sekitar 80,69% variansi biaya asuransi, yang merupakan performa awal yang cukup baik sebagai baseline.

4.3.2 K-Nearest Neighbors (KNN)

Penentuan nilai K optimal dilakukan menggunakan elbow method dengan mengevaluasi RMSE untuk K = 1 hingga K = 30. RMSE minimum diperoleh pada K = 3 dengan nilai RMSE sebesar 5.438,80.



Gambar 4.8 Elbow Method Pemilihan Nilai K Optimal pada KNN Regressor

Model KNN dengan K = 3 menghasilkan MAE sebesar \$3.220,47, RMSE sebesar \$5.438,80, dan R^2 sebesar 0,8390, lebih baik dari Linear Regression.

4.3.3 Random Forest

Model Random Forest dengan parameter default (`random_state=42`) dilatih menggunakan data mentah tanpa standarisasi. Hasilnya menunjukkan MAE sebesar \$2.633,36, RMSE sebesar \$4.680,15, dan R^2 sebesar 0,8808. Random Forest menjadi model terbaik sebelum tuning berkat kemampuannya menangani non-linearitas dan interaksi antar fitur tanpa asumsi distribusi.

4.3.4 XGBoost

Model XGBoost dengan parameter default (`random_state=42`) menghasilkan MAE sebesar \$3.011,55, RMSE sebesar \$5.096,55, dan R^2 sebesar 0,8586. Performa ini berada di antara KNN dan Random Forest. Tanpa tuning, XGBoost belum mencapai potensi optimalnya karena model ini sangat sensitif terhadap konfigurasi hyperparameter.

4.3.5 Evaluasi Awal Perbandingan Model

Model	MAE	RMSE	R^2
Random Forest	2.633,36	4.680,15	0,8808
XGBoost	3.011,55	5.096,55	0,8586
KNN (k=3)	3.220,47	5.438,80	0,8390
Linear Regression	4.176,92	5.956,45	0,8069

Berdasarkan hasil tersebut, Random Forest dipilih sebagai model yang akan di-tuning lebih lanjut.

4.3.6 Hyperparameter Tuning Random Forest

Tuning dilakukan menggunakan GridSearchCV dengan 5-fold cross-validation dan metrik optimasi R^2 . Grid pencarian mencakup kombinasi berikut:

`n_estimators` : [100, 200, 300]

`max_depth` : [3, 4, 5]

`min_samples_split` : [2, 5, 10]

`min_samples_leaf` : [1, 2, 4]

Total kombinasi yang dievaluasi adalah $3 \times 3 \times 3 \times 3 = 81$ kombinasi parameter. Parameter terbaik yang ditemukan adalah `n_estimators=200`, `max_depth=4`, `min_samples_split=10`, dan `min_samples_leaf=4`, dengan CV R^2 sebesar 0,844. Setelah model terbaik dievaluasi pada data uji, diperoleh peningkatan R^2 dari 0,8808 menjadi $\approx 0,90$.


4.4 Analisis dan Interpretasi

4.4.1 Perbandingan Model Akhir

Tuning hyperparameter terbukti meningkatkan performa Random Forest secara signifikan. Selisih yang kecil antara CV score (0,844) dan test score ($\approx 0,90$) mengindikasikan model memiliki kemampuan generalisasi yang baik tanpa indikasi overfitting.

4.4.2 Analisis Scatter Plot Aktual vs Prediksi


Scatter plot antara nilai aktual dan nilai prediksi menunjukkan bahwa sebagian besar titik data mengikuti garis diagonal merah (garis ideal prediksi sempurna). Titik-titik yang menyimpang jauh dari garis diagonal umumnya berasal dari kelompok perokok dengan biaya klaim yang sangat tinggi, yang memang lebih sulit diprediksi secara presisi.



Gambar 4.9 Scatter Plot Nilai Aktual vs Nilai Prediksi Tuned Random Forest

4.4.3 Analisis Residual


Residual (selisih nilai aktual dan prediksi) tersebar secara relatif acak di sekitar garis $y = 0$, mengindikasikan bahwa model telah menangkap pola utama dalam data tanpa menyisakan pola sistematis. Namun, terdapat indikasi heteroskedastisitas ringan di mana variansi residual cenderung lebih besar pada nilai prediksi yang tinggi, yang berkaitan dengan kelompok perokok yang memiliki biaya klaim ekstrem.



Gambar 4.10 Residual Plot Model Tuned Random Forest

4.4.4 Feature Importance

Analisis feature importance pada model Tuned Random Forest menghasilkan temuan sebagai berikut. Variabel smoker mendominasi dengan kontribusi sebesar 69,2%, menjadikannya prediktor paling kuat dalam menentukan besarnya biaya asuransi kesehatan. Hal ini konsisten dengan temuan pada heatmap korelasi yang menunjukkan korelasi tertinggi antara smoker dan charges ($r = 0,79$). Variabel bmi dan age berada di posisi kedua dan ketiga, sedangkan fitur interaksi bmi_age berada di posisi keempat, membuktikan bahwa feature engineering yang dilakukan memberikan kontribusi nyata meskipun relatif kecil.



Gambar 4.11 Feature Importance Model Tuned Random Forest

Variabel region dan sex memiliki importance yang sangat rendah, mengindikasikan bahwa kedua variabel tersebut hampir tidak informatif dalam konteks dataset ini.

4.4.5 Kesimpulan Analisis

Model Tuned Random Forest merupakan model terbaik di antara seluruh model yang diuji dengan nilai R^2 tertinggi serta MAE dan RMSE terendah. Proses hyperparameter tuning menggunakan GridSearchCV dengan 5-fold cross-validation terbukti efektif meningkatkan performa dibandingkan konfigurasi default. Dominasi variabel smoker sebagai prediktor utama mengimplikasikan bahwa status merokok merupakan faktor risiko terbesar yang menentukan tingginya biaya klaim asuransi kesehatan, sehingga informasi ini dapat menjadi pertimbangan penting bagi perusahaan asuransi dalam proses penetapan premi.

BAB V

PENUTUP

5.1 Kesimpulan

Berdasarkan hasil penelitian yang telah dilakukan, dapat disimpulkan bahwa penerapan algoritma machine learning mampu menghasilkan model yang baik dalam memprediksi biaya asuransi kesehatan (*charges*) berdasarkan karakteristik peserta asuransi. Penelitian ini diawali dengan tahapan *Exploratory Data Analysis* (EDA) untuk memahami karakteristik data, dilanjutkan dengan proses *preprocessing*, *feature engineering*, serta pemodelan menggunakan beberapa algoritma regresi, yaitu Linear Regression, K-Nearest Neighbor (KNN), Random Forest, dan XGBoost.

Hasil pemodelan menunjukkan bahwa Random Forest yang telah dioptimasi melalui hyperparameter tuning menggunakan GridSearchCV merupakan model terbaik dalam penelitian ini. Model tersebut menghasilkan nilai MAE sebesar 2.412,31, RMSE sebesar 4.203,34, dan R^2 sebesar 0,9039. Hasil tersebut menunjukkan bahwa model mampu menjelaskan sekitar 90,39% variasi biaya asuransi kesehatan dengan tingkat kesalahan prediksi yang relatif rendah dibandingkan model lainnya.

Berdasarkan analisis *feature importance*, variabel smoker menjadi faktor yang paling berpengaruh terhadap biaya asuransi kesehatan, diikuti oleh variabel bmi, age, dan fitur interaksi bmi_age. Temuan ini menunjukkan bahwa kebiasaan merokok, kondisi indeks massa tubuh, dan usia peserta memiliki kontribusi yang signifikan dalam menentukan besarnya biaya asuransi kesehatan. Oleh karena itu, faktor-faktor tersebut dapat menjadi pertimbangan penting dalam proses prediksi maupun pengambilan keputusan yang berkaitan dengan pengelolaan biaya asuransi kesehatan.

5.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, terdapat beberapa saran yang dapat diberikan untuk pengembangan penelitian selanjutnya. Penelitian selanjutnya disarankan menggunakan dataset dengan jumlah observasi yang lebih besar dan cakupan data yang lebih luas

agar model dapat mempelajari pola hubungan antar variabel secara lebih optimal. Selain itu, penambahan variabel yang berkaitan dengan kondisi kesehatan peserta, seperti riwayat penyakit, tingkat aktivitas fisik, tekanan darah, riwayat kesehatan keluarga, maupun jenis pekerjaan, dapat dipertimbangkan karena berpotensi memberikan informasi tambahan yang berpengaruh terhadap biaya asuransi kesehatan. Dengan adanya variabel yang lebih beragam, diharapkan model dapat menghasilkan prediksi yang lebih akurat dan representatif.

Dari sisi pemodelan, penelitian selanjutnya dapat melakukan perbandingan dengan algoritma machine learning lainnya, seperti LightGBM, CatBoost, Support Vector Regression (SVR), maupun Neural Network. Selain itu, proses optimasi model dapat dilakukan lebih mendalam melalui teknik hyperparameter tuning yang lebih luas atau menggunakan metode optimasi lain, seperti Random Search dan Bayesian Optimization. Langkah tersebut diharapkan dapat meningkatkan performa model sehingga menghasilkan tingkat kesalahan prediksi yang lebih rendah dan kemampuan prediksi yang lebih baik.

Dari sisi implementasi, model yang dihasilkan pada penelitian ini dapat dikembangkan menjadi sebuah sistem atau aplikasi prediksi biaya asuransi kesehatan yang dapat digunakan secara praktis. Sistem tersebut dapat membantu perusahaan asuransi dalam memperkirakan biaya kesehatan peserta secara lebih cepat, konsisten, dan berbasis data. Selain itu, informasi mengenai faktor-faktor yang paling berpengaruh terhadap biaya asuransi kesehatan juga dapat dimanfaatkan sebagai bahan pertimbangan dalam penyusunan kebijakan, pengelolaan risiko, serta pengambilan keputusan yang lebih efektif di bidang asuransi kesehatan.

LAMPIRAN

Link Github:

<https://github.com/nnasiwaaahh/PROJEK-MACHINE-LEARNING-KELOMPOK-D-STATISTIKA-B>

Link AI yang digunakan :

<https://claude.ai/share/fdca74cd-a2b3-4e68-aa2c-d60831cc03c6>
<https://chatgpt.com/c/6a3a292d-5a18-83ec-a576-94a7cb587f60>

Link Google Colab

<https://colab.research.google.com/drive/1y8ECa4Vq6vORxM1KLnNOvNUJnTPGhG77?usp=sharing>