


Machine Learning  
Project

Group D

# Medical cost



Our  
Team



Nasywa Putri M.

043



Nadia Marsha

046




Raditya Akbar F.

063



Kezya Aurell M. S.

071



# Latar Belakang

## Medical Cost

Pendahuluan

Perkembangan teknologi informasi dan ketersediaan data yang besar mendorong pemanfaatan machine learning dalam berbagai bidang, termasuk asuransi kesehatan. Pada penelitian ini, machine learning digunakan untuk memprediksi biaya asuransi kesehatan (charges) berdasarkan karakteristik peserta, yaitu usia (age), jenis kelamin (sex), indeks massa tubuh (bmi), jumlah tanggungan (children), status merokok (smoker), dan wilayah tempat tinggal (region). Prediksi biaya kesehatan penting untuk mendukung penentuan premi, pengelolaan risiko, dan perencanaan keuangan perusahaan asuransi. Penelitian ini bertujuan membangun dan membandingkan beberapa model regresi machine learning untuk memperoleh model prediksi terbaik serta mengidentifikasi faktor-faktor yang paling berpengaruh terhadap biaya asuransi kesehatan.

# Rumusan Masalah

- Bagaimana karakteristik dan pola data pada dataset Insurance berdasarkan hasil Exploratory Data Analysis (EDA)?
- Bagaimana proses preprocessing dan feature engineering yang tepat untuk meningkatkan kualitas data sebelum pemodelan?
- Bagaimana performa beberapa algoritma machine learning dalam memprediksi biaya asuransi kesehatan (charges)?
- Model machine learning manakah yang memberikan hasil prediksi terbaik berdasarkan matrik evaluasi yang digunakan?
- Faktor-faktor apa saja yang paling berpengaruh terhadap biaya asuransi kesehatan berdasarkan hasil interpretasi model?




# Tujuan Penelitian

- Melakukan eksplorasi data untuk memahami karakteristik dan pola pada dataset Insurance.
- Menerapkan tahapan preprocessing dan feature engineering guna mempersiapkan data untuk proses pemodelan.
- Membangun dan membandingkan beberapa algoritma machine learning untuk memprediksi biaya asuransi kesehatan.
- Mengevaluasi dan menentukan model terbaik berdasarkan hasil pengukuran performa model.
- Mengidentifikasi faktor-faktor yang paling berpengaruh terhadap biaya asuransi kesehatan melalui analisis feature importance atau interpretasi model.



| age | sex    | bmi    | children | smoker | region    | charges     |
|-----|--------|--------|----------|--------|-----------|-------------|
| 19  | female | 27.9   | 0        | yes    | southwest | \$16,884.92 |
| 18  | male   | 33.77  | 1        | no     | southeast | \$1,725.55  |
| 28  | male   | 33     | 3        | no     | southeast | \$4,449.46  |
| 33  | male   | 22.705 | 0        | no     | northwest | \$21,984.47 |
| ... | ...    | ...    | ...      | ...    | ...       | ...         |


<https://bit.ly/Data-Full-ML-GroupD>



Data  
Set

# Eksplorasi Data

## Visualisasi




## Eksplorasi Data

## Medical Cost

dataset terdiri dari 1.338 baris dan 7 kolom biaya asuransi kesehatan individu tanpa nilai kosong dan tipe data yang sesuai. Rata-rata usia adalah 39 tahun, rata-rata BMI 30.66 (overweight), dan rata-rata 1 tanggungan. Biaya asuransi rata-rata \$13270.42 dengan distribusi right-skewed. Terdapat 1 duplikat yang perlu ditangani. Distribusi gender seimbang, sedangkan perokok (smoker) tidak seimbang (sekitar 21% perokok) tetapi ini mencerminkan distribusi populasi yang nyata.

# Pre-Processing

## Heatmap Matriks Korelasi



## Pre-Processing

## Medical Cost

Proses pre-processing data diawali dengan penghapusan duplikat yang terdeteksi pada tahap eksplorasi data tadi, diikuti oleh pengkodean variabel kategorik: kolom 'sex' dan 'smoker' diubah menjadi biner (0/1), sedangkan 'region' di-encode menjadi one-hot untuk merepresentasikan wilayah secara numerik. Selanjutnya, dilakukan rekayasa fitur dengan membuat kolom interaksi 'bmi\_age' sebagai hasil perkalian 'bmi' dan 'age' untuk menangkap hubungan kompleks antar keduanya, yang kemudian diperkuat oleh hasil korelasi yang menunjukkan relevansinya dengan 'charges'. Tahap akhir pra-pemrosesan melibatkan pembagian data menjadi set pelatihan dan pengujian (80:20) dan standarisasi fitur numerik menggunakan StandardScaler, yang penting untuk model yang sensitif terhadap skala seperti KNN.

# Permodelan

## Hasil Permodelan

### Regresi Linier

MAE : 4176.916171448353  
RMSE : 5956.447542223982  
R<sup>2</sup> : 0.8069219238646148

### KNN

MAE : 3220.4749971554725  
RMSE : 5438.795908202173  
R<sup>2</sup> : 0.8390229945039492

### Tuning Random Forest

MAE : 2412.3094522519536  
RMSE : 4203.335995164277  
R<sup>2</sup> : 0.9038506098808691

### Random Forest

MAE : 2633.3621103171636  
RMSE: 4680.1527724755315  
R<sup>2</sup> : 0.88079941694435

### XGBoost

MAE : 3011.549557593997  
RMSE: 5096.551694747583  
R<sup>2</sup> : 0.8586449959473182


## Permodelan

## Medical Cost

Berdasarkan hasil evaluasi model, Random Forest menunjukkan performa terbaik dengan R<sup>2</sup> tertinggi sebesar 0.8807, serta MAE dan RMSE terendah dibandingkan model Linear Regression (R<sup>2</sup> 0.8069), KNN (R<sup>2</sup> 0.8390), dan XGBoost (R<sup>2</sup> 0.8586). Ini menunjukkan bahwa Random Forest memiliki kemampuan prediksi paling akurat dan secara efektif menangkap pola dalam data untuk memprediksi biaya asuransi, dengan rata-rata kesalahan absolut terendah sekitar \$2633.36. Namun Setelah dilakukan Hyperparameter Tuning dengan GridSearchCV Performa Model Random Forest Meningkat dari 0,88 menjadi 0,90 menjadikan Tuned Random Forest Sebagai Model Terbaik

# Evaluasi

## Feature Importance



## Evaluasi

## Medical Cost

Berdasarkan evaluasi model, Random Forest yang telah di-tuning muncul sebagai model terbaik dengan performa tertinggi ( $R^2$  sekitar 0.90) dibandingkan model lain seperti Linear Regression, KNN, dan XGBoost, menunjukkan kemampuannya yang unggul dalam memprediksi biaya asuransi. Peningkatan performa ini dicapai melalui hyperparameter tuning, yang mengoptimalkan model untuk menangani non-linearitas dan interaksi fitur. Analisis feature importance secara jelas menyoroti 'smoker' sebagai prediktor biaya asuransi yang paling dominan dan signifikan, diikuti oleh 'bmi' dan 'age', sementara variabel 'region' dan 'sex' terbukti memiliki kontribusi yang sangat minimal terhadap prediksi.



## Kesimpulan

---

Berdasarkan hasil penelitian, dataset Insurance tidak memiliki missing value dan hanya terdapat satu data duplikat yang dihapus pada tahap preprocessing. Model yang dibangun menggunakan Linear Regression, KNN, Random Forest, dan XGBoost menunjukkan bahwa Random Forest memiliki performa terbaik. Setelah dilakukan hyperparameter tuning dengan GridSearchCV, model Random Forest memperoleh MAE 2.412,31, RMSE 4.203,34, dan  $R^2$  0,9039, sehingga mampu menjelaskan 90,39% variasi biaya asuransi kesehatan. Analisis feature importance menunjukkan bahwa variabel smoker, bmi, age, dan bmi\_age merupakan faktor yang paling berpengaruh dalam memprediksi biaya asuransi kesehatan.

# Kesim- Pulan

# Thank You!

Any Questions?



Scan for  
More!

